

Upute za izradu završnog rada

Web aplikacija u Pythonu za izračun i aproksimaciju otkupnih vrijednosti životnog osiguranja

1. Što je točno zadatak rada?

Zadatak je napraviti funkcionalnu Python web aplikaciju koja:

1. koristi postojeću aktuarsku osnovu iz priložene tehničke dokumentacije;
2. izračunava neto premiju, bruto premiju, matematičku pričuvu i otkupnu vrijednost prema zadanim formulama;
3. provjerava ispravnost izračuna usporedbom s kontrolnim tablicama premija iz dokumenta;
4. nakon toga generira simulirani skup valjanih scenarija;
5. trenira nekoliko regresijskih modela strojnog učenja na tom skupu;
6. uspoređuje ML procjenu s referentnom aktuarskom vrijednošću;
7. rezultate prikazuje kroz jednostavno web sučelje.

U radu se koristi aktuarska osnova iz dokumenta: tablice mortaliteta Republike Hrvatske 2010.–2012., tehnička godišnja kamatna stopa 0,25%, zadani omjeri osiguranih iznosa, troškovi i formule. Na početku treba napraviti strukturu projekta:

```
zavrsni_rad/
|-- data/
|   |-- mortality_2010_2012.csv
|   |-- validation_premiums.csv
|   |-- ml_scenarios.csv
|-- src/
|   |-- mortality.py
|   |-- commutation.py
|   |-- actuarial_calculator.py
|   |-- generate_dataset.py
|   |-- train_models.py
|-- app.py
|-- requirements.txt
|-- README.md
```

U datoteci `requirements.txt` navesti barem:

```
numpy
pandas
scikit-learn
streamlit
matplotlib
```

U datoteci `README.md` kratko opisati kako se pokreće aplikacija, primjerice:

```
streamlit run app.py
```

2. Pripremiti podatke iz tehničkog dokumenta

2.1. Tablica mortaliteta

U priloženoj tehničkoj dokumentaciji već se nalazi uprosječena tablica smrtnosti za Republiku Hrvatsku 2010.–2012. Tablica je prikazana u obliku

$$x = \text{starost u godinama}, \quad l_x = \text{broj živih u dobi } x.$$

Prema dokumentu, ta je tablica dobivena iz Tablica mortaliteta Republike Hrvatske 2010.–2012., uz uprosječenje prema spolu s udjelom muškaraca od 60% i žena od 40%. Budući da je u dokumentu već

dana konačna uprosječena tablica, u ovom radu nije potrebno ponovno računati ponderiranje prema spolu. Student treba iz tablice sa stranice 4. tehničke dokumentacije prepisati vrijednosti u CSV datoteku pod nazivom `mortality_2010_2012.csv`. Datoteka treba imati barem sljedeće stupce:

Naziv stupca	Značenje	Primjer
<code>age_years</code>	starost u godinama	18
<code>lx</code>	broj živih u toj dobi	99452

Nakon toga treba iz godišnje tablice napraviti mjesečnu tablicu smrtnosti, jer se u formulama iz dokumenta pristupna dob x , trajanje osiguranja n i proteklo vrijeme t izražavaju u mjesecima. Ako su poznate vrijednosti l_a i l_{a+1} za dvije susjedne dobi u godinama, vrijednost za dob a godina i r mjeseci računa se linearnom interpolacijom:

$$l_{a+r/12} = \left(1 - \frac{r}{12}\right) l_a + \frac{r}{12} l_{a+1}, \quad r = 0, 1, \dots, 11.$$

Tako se dobiva mjesečna tablica oblika:

Naziv stupca	Značenje	Primjer
<code>age_months</code>	starost u mjesecima	216
<code>age_years</code>	starost izražena u godinama	18.0000
<code>lx</code>	interpolirani broj živih	99452

2.2. Ulazni parametri police

U kalkulatoru treba koristiti ove ulaze:

x = pristupna dob u mjesecima, n = trajanje police u mjesecima, t = proteklo vrijeme u mjesecima,

OIS = osigurani iznos za slučaj smrti, OID = osigurani iznos za slučaj doživljenja.

Potrebno je ugraditi sljedeće provjere:

$$216 \leq x \leq 780, \quad 24 \leq n \leq 420, \quad x + n \leq 900, \quad 0 \leq t \leq n.$$

To znači: pristupna dob je od 18 do 65 godina, trajanje osiguranja od 2 do 35 godina, a osiguranik pri isteku police ne smije imati više od 75 godina. Omjer osiguranih iznosa je

$$k = \frac{\text{OIS}}{\text{OID}}.$$

Za prvu verziju rada koristiti samo omjere iz dokumenta:

$$k \in \left\{ \frac{1}{5}, \frac{1}{4}, \frac{1}{3}, \frac{1}{2}, 1, 2, 3, 4, 5 \right\}.$$

Sigurnosna margina za rizik smrti određuje se prema:

$$\delta = \begin{cases} 0, & k \leq 1, \\ 0,25, & k = 2, \\ 0,50, & k = 3, \\ 0,75, & k = 4, \\ 1, & k = 5. \end{cases}$$

3. Izračun komutativnih brojeva

U modulu `commutation.py` treba napisati funkcije koje iz mjesečne tablice smrtnosti i kamatne stope računaju komutativne brojeve D_x , N_x i M_x .

Važna napomena. Tehnička dokumentacija koristi oznake D_x , N_x i M_x , ali ne navodi eksplicitne formule prema kojima su ti komutativni brojevi izračunati. Zbog toga se u radu najprije uvodi standardna implementacijska pretpostavka za mjesečne komutativne brojeve, a zatim se ispravnost te pretpostavke provjerava usporedbom izračunatih neto premija s kontrolnim tablicama iz dokumenta.

Najosjetljiviji dio je konstrukcija broja M_x , jer ona ovisi o pretpostavci o trenutku isplate i diskontiranja naknade za slučaj smrti. Ako Python izračun ne reproducira kontrolne neto premije iz dokumenta, potrebno je najprije provjeriti mjesečnu kamatnu stopu, linearnu interpolaciju tablice smrtnosti i konvenciju korištenu pri izračunu M_x .

Godišnja tehnička kamatna stopa iz dokumenta je:

$$i = 0,25\% = 0,0025.$$

Za mjesečni obračun kao početnu pretpostavku koristiti efektivnu mjesečnu stopu:

$$i_m = (1 + i)^{1/12} - 1,$$

a mjesečni diskontni faktor:

$$v_m = \frac{1}{1 + i_m}.$$

Kao početnu implementacijsku pretpostavku za svaki mjesec dobi izračunati:

$$D_x = v_m^x l_x.$$

Ako je

$$d_x = l_x - l_{x+1}$$

broj umrlih između mjeseca x i mjeseca $x + 1$, tada se za komutativne brojeve povezane s rizikom smrti može koristiti oblik:

$$C_x = v_m^{x+1} d_x, \quad M_x = \sum_{j=x}^{\omega} C_j.$$

Također:

$$N_x = \sum_{j=x}^{\omega} D_j.$$

Ovdje ω označava najveću dob u tablici. Budući da dokument ne daje potpunu definiciju komutativnih brojeva, ove formule treba smatrati početnom implementacijskom pretpostavkom. Ako rezultati ne reproduciraju kontrolne tablice neto premija iz dokumenta, ne prelazi se na izračun otkupnih vrijednosti ni na strojno učenje. Najprije treba provjeriti:

- je li dobro unesena tablica smrtnosti;
- je li pravilno napravljena mjesečna linearna interpolacija;
- je li godišnja kamatna stopa pravilno pretvorena u mjesečnu;
- je li ispravno izračunat D_x ;
- je li ispravno izračunat N_x ;
- je li za M_x korištena odgovarajuća konvencija diskontiranja naknade za slučaj smrti;
- je li ispravno primijenjena tehnička margina sigurnosti δ .

Validacija iz poglavlja 5 pokazuje je li implementacija komutativnih brojeva usklađena s tehničkom dokumentacijom.

4. Implementirati aktuarski kalkulator

U modulu `actuarial_calculator.py` treba napisati glavnu funkciju, primjerice:

```
calculate_policy(age_months, duration_months, elapsed_months, OIS, OID)
```

Funkcija mora napraviti sljedeće:

1. provjeriti jesu li ulazi dopušteni;
2. izračunati $k = \text{OIS}/\text{OID}$;
3. odrediti δ ;
4. dohvatiti potrebne vrijednosti $D_x, D_{x+n}, D_{x+t}, N_x, N_{x+n}, N_{x+t}, M_x, M_{x+n}$ i M_{x+t} ;
5. izračunati neto premiju;
6. izračunati bruto premiju;
7. izračunati matematičku pričuvu;
8. izračunati otkupnu vrijednost;
9. vratiti rezultate u obliku rječnika ili tablice.

4.1. Neto premija

Implementirati:

$$P_{x,n}^S = \text{OIS}(1 + \delta) \frac{M_x - M_{x+n}}{N_x - N_{x+n}},$$

$$P_{x,n}^D = \text{OID} \frac{D_{x+n}}{N_x - N_{x+n}},$$

$$P_{x,n} = P_{x,n}^S + P_{x,n}^D.$$

4.2. Bruto premija

Iz dokumenta preuzeti troškovne parametre α i γ za odgovarajući cjenik. Zatim implementirati:

$$BP_{x,n}^S = \frac{P_{x,n}^S}{1 - \alpha - \gamma}, \quad BP_{x,n}^D = \frac{P_{x,n}^D}{1 - \alpha - \gamma},$$

$$BP_{x,n} = BP_{x,n}^S + BP_{x,n}^D.$$

4.3. Matematička pričuva

Za trenutak t implementirati:

$${}_tV_{x,n}^{OS} = \text{OIS}(1 + \delta) \frac{M_{x+t} - M_{x+n}}{D_{x+t}} + \text{OID} \frac{D_{x+n}}{D_{x+t}} - P_{x,n} \frac{N_{x+t} - N_{x+n}}{D_{x+t}}.$$

4.4. Otkupna vrijednost

Implementirati:

$${}_tO_{x,n} = \min \left\{ \text{OIS}, 0,97 \cdot {}_tV_{x,n}^{OS} \right\}.$$

Kao dodatnu programsku zaštitu može se prikazati upozorenje ako izračun dovede do negativne vrijednosti pričuve ili otkupne vrijednosti, ali ne treba mijenjati formulu bez opravdanja iz dokumenta.

5. Validirati kalkulator prema tablicama iz dokumenta

Prije strojnog učenja obavezno provjeriti daje li Python iste vrijednosti premija kao dokument. U datoteku `validation_premiums.csv` ručno unijeti najmanje 30 kontrolnih kombinacija iz tablica dokumenta. Treba uzeti različite dobi, trajanja i odnose OIS/OID. Datoteka treba imati stupce:

age_years	duration_years	OIS	OID	net_doc	gross_doc
-----------	----------------	-----	-----	---------	-----------

Za svaki redak izračunati:

$$\text{net_python}, \quad \text{gross_python},$$

pa zatim:

$$\begin{aligned} \text{abs_error_net} &= |\text{net_doc} - \text{net_python}|, \\ \text{abs_error_gross} &= |\text{gross_doc} - \text{gross_python}|. \end{aligned}$$

U izvješću prikazati tablicu:

Dob	Trajanje	OIS	OID	Dokument	Python	Razlika
...	...	...	...	...	...	...

Kriterij prihvatljivosti: prosječna apsolutna pogreška treba biti vrlo mala, a odstupanja smiju nastati uglavnom zbog zaokruživanja. Ako se neto premije dobro podudaraju, a bruto premije ne, problem je najvjerojatnije u izboru troškovnih parametara α i γ . Ako se ne podudaraju ni neto premije, problem treba tražiti u tablici smrtnosti, interpolaciji, kamatnoj stopi, komutativnim brojevima ili tehničkoj margini δ . Ako odstupanja nisu mala, ne prelaziti na ML dio. Prvo provjeriti:

- je li dobro unesena tablica mortaliteta;
- je li dobra mjesečna interpolacija;
- je li dobro pretvorena godišnja kamata u mjesečnu;
- jesu li ispravno izračunati D_x , N_x i M_x ;
- jesu li ispravno uneseni α , γ , OIS, OID i δ ;
- je li primijenjeno isto zaokruživanje kao u dokumentu.

6. Generirati skup podataka za strojno učenje

Tek nakon uspješne validacije generirati skup `ml_scenarios.csv`. Jedan redak predstavlja jednu policu u jednom trenutku t . Za prvu verziju rada koristiti samo ove kombinacije:

$$\begin{aligned} (\text{OIS}, \text{OID}) \in \{ & (1000, 5000), (1000, 4000), (1000, 3000), (1000, 2000), (1000, 1000), \\ & (2000, 1000), (3000, 1000), (4000, 1000), (5000, 1000) \}. \end{aligned}$$

Preporučeni postupak:

1. generirati približno 10 000 osnovnih polica;
2. za svaku policu slučajno odabrati x , n , OIS i OID tako da vrijede sva ograničenja;
3. za svaku policu izračunati nekoliko trenutaka t ;
4. za svaki redak pomoću aktuarskog kalkulatora izračunati ciljnu vrijednost ${}_tO_{x,n}$;
5. spremiti sve u `ml_scenarios.csv`.

Osnovna polica definira se kao:

$$\text{policy_id} = (x, n, \text{OIS}, \text{OID}).$$

Za svaku policu uzeti, primjerice:

$$t \in \{ \lfloor 0,10n \rfloor, \lfloor 0,25n \rfloor, \lfloor 0,50n \rfloor, \lfloor 0,75n \rfloor, n \}.$$

Ako se generira 10 000 polica i po pet trenutaka po polici, dobiva se približno 50 000 redaka. CSV datoteka za ML treba imati stupce:

Stupac	Uloga	Tip	Primjer	Objašnjenje
policy_id	grupa	int	17	svi trenuci iste police imaju isti ID
x	ulaz	int	360	pristupna dob u mjesecima
n	ulaz	int	240	trajanje police u mjesecima
t	ulaz	int	60	proteklo vrijeme u mjesecima
OIS	ulaz	float	1000	iznos za slučaj smrti
OID	ulaz	float	5000	iznos za slučaj doživljenja
k	ulaz	float	0.2	omjer OIS/OID
delta	ulaz	float	0	sigurnosna margina
surrender_value	cilj	float	732.15	otkupna vrijednost iz formule

7. Podijeliti podatke na trening, validaciju i test

Podatke ne dijeliti nasumično po redcima, jer bi se trenuci iste police mogli pojaviti i u treningu i u testu. To bi dalo umjetno dobre rezultate. Dijeljenje treba napraviti prema `policy_id`:

70% osnovnih polica za trening, 15% za validaciju, 15% za test.

Svi redci iste police moraju ostati u istom skupu. U Pythonu koristiti `GroupShuffleSplit` ili ručno podijeliti jedinstvene vrijednosti `policy_id`. Ulazne varijable za ML model:

$$X = (x, n, t, \text{OIS}, \text{OID}, k, \delta).$$

Ciljna varijabla:

$$y = {}_tO_{x,n}.$$

Ako se koristi OIS i OID, varijabla k je izvedena varijabla. Može se uključiti radi lakšeg učenja modela, ali u izvješću treba navesti da proizlazi iz OIS i OID.

8. Trenirati i usporediti modele

U modulu `train_models.py` trenirati barem:

1. linearnu regresiju;
2. stablo odlučivanja za regresiju;
3. slučajnu šumu, ako opseg rada dopušta.

Za svaki model izračunati:

$$MAE = \frac{1}{m} \sum_{j=1}^m |y_j - \hat{y}_j|,$$

$$RMSE = \sqrt{\frac{1}{m} \sum_{j=1}^m (y_j - \hat{y}_j)^2},$$

$$R^2 = 1 - \frac{\sum_{j=1}^m (y_j - \hat{y}_j)^2}{\sum_{j=1}^m (y_j - \bar{y})^2}.$$

Dodatno izračunati najveću apsolutnu pogrešku:

$$\max_j |y_j - \hat{y}_j|.$$

Rezultate prikazati u tablici:

Model	MAE	RMSE	R^2	Najveća pogreška
Linearna regresija	...	...	...	...
Stablo odlučivanja	...	...	...	...
Slučajna šuma	...	...	...	...

U tekstu rada obavezno objasniti:

$$\hat{f}_{\text{ML}}(x, n, t, \text{OIS}, \text{OID}) \approx f_{\text{akt}}(x, n, t, \text{OIS}, \text{OID}),$$

odnosno ML model aproksimira aktuarsku formulu. Ne tvrditi da je ML model točniji od formule iz tehničke dokumentacije.

9. Izraditi web aplikaciju

Aplikaciju izraditi pomoću **Streamlit** ili sličnog alata. Korisniku omogućiti unos:

- pristupne dobi u godinama ili mjesecima;
- trajanja police u godinama ili mjesecima;
- proteklog vremena t ;
- osiguranog iznosa za slučaj smrti OIS;
- osiguranog iznosa za slučaj doživljenja OID.

Aplikacija mora:

1. provjeriti jesu li unesene vrijednosti dopuštene;
2. izračunati k i δ ;
3. prikazati neto premiju $P_{x,n}$;
4. prikazati bruto premiju $BP_{x,n}$;
5. prikazati matematičku pričuvu ${}_tV_{x,n}^{OS}$;
6. prikazati otkupnu vrijednost ${}_tO_{x,n}$;
7. po želji prikazati ML procjenu $\hat{O}_{x,n}$;
8. prikazati razliku između ML procjene i aktuarske vrijednosti.

Primjer izlaza aplikacije:

Veličina	Vrijednost
Neto mjesečna premija	...
Bruto mjesečna premija	...
Matematička pričuva	...
Otkupna vrijednost – aktuarski izračun	...
Otkupna vrijednost – ML procjena	...
Apsolutno odstupanje	...

10. Što predati na kraju?

Na kraju treba predati:

1. CSV datoteku s tablicom mortaliteta;
2. CSV datoteku s kontrolnim vrijednostima za validaciju premija;
3. Python kod za aktuarski kalkulator;
4. tablicu validacije kalkulatora prema dokumentu;
5. generirani ML skup `ml_scenarios.csv`;
6. kod za treniranje i evaluaciju modela;
7. funkcionalnu web aplikaciju;
8. završni tekst rada s opisom metoda, rezultata i ograničenja.

Točan redoslijed rada je:

tablica mortaliteta → komutativni brojevi → aktuarski kalkulator → validacija.

ML skup → ML modeli → web aplikacija.